

# Weather-Driven Procurement Model

Case Study: Prognozowanie popytu na parasole na podstawie pogody i translacja prognozy w decyzję zakupową

**Cel projektu:** Zbudować w Excelu kompletny model, który na podstawie prognozy pogody (opad, temperatura, wiatr) przewiduje popyt na parasole i automatycznie wylicza: ile zamówić, kiedy zamówić, jaki bufor bezpieczeństwa utrzymać.

**90.4%**

R<sup>2</sup> (Model Accuracy)

**406**

Standard Error (units)

**19**

Months of Data

**3**

Weather Variables

## 1. Problem biznesowy

Firma "The Umbrella Company" sprzedaje parasole. Sprzedaż silnie zależy od pogody — im więcej deszczu, tym większy popyt. Jako **Procurement Manager** musisz odpowiedzieć na pytania:

- **Ille zamówić** na kolejny miesiąc?
- **Kiedy złożyć zamówienie** (punkt zamówienia)?
- **Jaki bufor trzymać** na niepewność prognozy?
- **Jak wykorzystać prognozę pogody** do planowania zakupów?

Tradycyjne podejście "na czuja" lub średnia historyczna nie uwzględnia kluczowego drivera — pogody. Dlatego zbudowaliśmy **driver-based forecasting model**.

## 2. Dane wejściowe

Dysponowaliśmy danymi miesięcznymi za okres 19 miesięcy (czerwiec 2023 – grudzień 2024):

Zmienna	Opis	Zakres wartości
Rainfall (mm)	Suma opadów w miesiącu	42 – 118 mm
Temperature (°C)	Średnia temperatura	3 – 31°C
Wind Speed (km/h)	Średnia prędkość wiatru	10 – 19 km/h
Quantity Sold	Sprzedaż parasoli (szt.)	1,745 – 5,555 szt.

### 3. Model regresji (Driver-Based Forecasting)

#### Model 1: Tylko opad (Simple Regression)

Najpierw sprawdziliśmy, czy sam opad wystarczy do prognozowania popytu:

```
Demand = Intercept + b_Rainfall × Rainfall
```

```
Demand = -630.33 + 47.14 × Rainfall
```

Metryka	Wartość	Interpretacja
R <sup>2</sup>	<b>0.822 (82%)</b>	Model wyjaśnia 82% zmienności popytu
Standard Error	518 szt.	Typowy błąd prognozy
Współczynnik Rainfall	+47.14	+1 mm deszczu → +47 parasoli
P-value (Rainfall)	8.73E-08	Statystycznie bardzo istotne

**Wniosek:** Opad jest bardzo silnym driverem popytu. Każdy dodatkowy 1 mm deszczu oznacza średnio +47 sprzedanych parasoli.

#### Model 2: Opad + Temperatura + Wiatr (Multiple Regression)

Rozszerzyliśmy model o dodatkowe zmienne pogodowe:

```
Demand = Intercept + b_Rain × Rain + b_Temp × Temp + b_Wind × Wind
```

```
Demand = -2971.68 + 58.40 × Rain + 55.76 × Temp + 32.90 × Wind
```

R <sup>2</sup>	82.2%	<b>90.4% ✓</b>
Standard Error	518 szt.	<b>406 szt. ✓</b>
Rainfall (p-value)	<b>✓ istotny</b>	<b>✓ istotny</b>
Temperature (p-value)	—	<b>✓ istotny (p=0.025)</b>
Wind (p-value)	—	<b>X nieistotny (p=0.68)</b>

**Uwaga:** Wind Speed nie jest statystycznie istotny (p-value = 0.68 > 0.05). W produkcyjnym modelu można go usunąć dla uproszczenia. Zostawiliśmy go dla celów demonstracyjnych.

## 4. Logika Procurement (od prognozy do zamówienia)

Prognoza popytu to dopiero początek. Jako Procurement Manager musisz przełożyć ją na konkretną decyzję zakupową. Oto pełny łańcuch:



1

### Demand Forecast (Prognoza popytu)

Wstawiamy prognozę pogody do równania regresji i otrzymujemy oczekiwany popyt na miesiąc.

$$\text{Demand\_Forecast} = \text{Intercept} + b_{\text{Rain}} \times \text{Rain} + b_{\text{Temp}} \times \text{Temp} + b_{\text{Wind}} \times \text{Wind}$$

2

### DLT — Demand During Lead Time (Popyt w czasie dostawy)

Ile sztuk "zejedzie" w czasie, gdy czekasz na dostawę od momentu złożenia zamówienia.

$$DLT = \text{Demand\_Forecast} \times \text{Lead\_Time\_months}$$

3

### Safety Stock (Zapas bezpieczeństwa)

Bufor na niepewność prognozy. Liczymy go z błędem modelu ( $\text{Sigma}_{\text{Residual}}$ ) i poziomu obsługi (Service Level).

$$\begin{aligned}z &= \text{NORM.S.INV}(\text{Service\_Level}) \\ \text{Sigma\_LT} &= \text{Sigma}_{\text{Residual}} \times \sqrt{(\text{Lead\_Time\_months})} \\ \text{Safety\_Stock} &= z \times \text{Sigma\_LT}\end{aligned}$$

Dla Service Level = 95% →  $z \approx 1.645$

4

### ROP — Reorder Point (Punkt zamówienia)

Poziom zapasu, przy którym powinieneś złożyć zamówienie, żeby nie zabrakło towaru.

$$\text{ROP} = \text{DLT} + \text{Safety\_Stock}$$

5

### Inventory Position (Pozycja zapasu)

Nie tylko to co masz na magazynie, ale też to co jest już zamówione i w drodze.

$$\text{Inventory\_Position} = \text{Stock\_On\_Hand} + \text{On\_Order}$$

6

### Order Quantity (Ile zamówić)

Różnica między ROP a tym co masz.  $\text{MAX}(0, \dots)$  zapobiega ujemnym zamówieniom.

$$\text{Order\_Q} = \text{MAX}(0, \text{ROP} - \text{Inventory\_Position})$$

7

### Order MOQ (Zaokrąglenie do minimalnej partii)

Dostawcy często wymagają zamówień w pełnych kartonach/paletach. CEILING.MATH zaokrąglą w góre.

Order\_Q\_MOQ = CEILING.MATH(Order\_Q, MOQ)

## 5. Przykład: Styczeń 2025

### Dane wejściowe (Inputs)

Parametr	Wartość
Forecast Rain (mm)	90
Forecast Temperature (°C)	5
Forecast Wind (km/h)	18
Service Level	95%
Lead Time	30 dni (1 miesiąc)
Stock On Hand	2,100 szt.
On Order	700 szt.
MOQ	200 szt.

### Obliczenia (Calculations)

Krok	Formuła	Wynik
Demand Forecast	$-2971.68 + 58.40 \times 90 + 55.76 \times 5 + 32.90 \times 18$	<b>3,156 szt.</b>
DLT	$3,156 \times 1$	3,156 szt.
z (dla 95%)	NORM.S.INV(0.95)	1.645
Sigma_LT	$406 \times \sqrt{1}$	406
Safety Stock	$1.645 \times 406$	<b>668 szt.</b>
ROP	$3,156 + 668$	<b>3,824 szt.</b>

Inventory Position	2,100 + 700	2,800 szt.
Order_Q	MAX(0, 3824 - 2800)	1,024 szt.
Order_Q_MOQ	CEILING.MATH(1024, 200)	<b>1,200 szt.</b>

## DECYZJA ZAKUPOWA

# ZAMÓW 1,200 szt.

Reorder Flag: ORDER (Inventory Position 2,800 < ROP 3,824)

## 6. Struktura pliku Excel

Arkusz	Zawartość
<b>Data</b>	Dane historyczne (19 miesięcy): Rain, Temp, Wind, Sales
<b>Regression_Output</b>	Wynik regresji prostej (tylko Rainfall) — $R^2 = 82\%$
<b>Procurement_Plan</b>	Kalkulator ROP/SS/Order dla modelu 1-zmiennego
<b>Regression_Output_Weather</b>	Wynik regresji wielorakiej (Rain+Temp+Wind) — $R^2 = 90\%$
<b>Procurement_Plan_Weather</b>	Pełny kalkulator procurement dla modelu pogodowego

## 7. Zastosowane umiejętności

Regresja liniowa	Regresja wieloraka	Driver-based forecasting	Safety Stock	Reorder Point (ROP)
MOQ handling	Named ranges (Excel)	Conditional formatting	NORM.S.INV	CEILING.MATH

## 8. Wnioski i rekomendacje

### Kluczowe wnioski:

- Pogoda jest silnym driverem popytu** — model z 3 zmiennymi wyjaśnia 90% zmienności sprzedaży
- Rainfall i Temperature** są statystycznie istotne; Wind — nie

- **Model 3-zmienny ma mniejszy błąd** (406 vs 518) → mniejszy Safety Stock → niższe koszty zapasu
- **Automatyzacja w Excelu** pozwala na szybkie przeliczanie scenariuszy (low/base/high rain)

## Możliwe rozszerzenia:

- Dodanie sezonowości (miesiąc jako zmienna dummy)
- Użycie liczby "dni deszczowych" zamiast sumy mm
- Wdrożenie w Power BI z automatycznym pobieraniem prognozy pogody
- Rozszerzenie na wiele SKU z różnymi współczynnikami

## Autor

**Marcin Banach**

GitHub: [@mbimarban](#)

Jeśli ten projekt był pomocny, zostaw gwiazdkę na GitHubie!